


INTELIGENCIA ARTIFICIAL II

DETECCION TEMPRANA DE

ENFERMEDADES EN LA

PIEL

Jhon Anderson Amaya Lopez – 2220092
Sergio Hernando Barón Rivera – 2201885




MOTIVACIÓN

- Según la IARC, el cáncer de piel es el más común en Estados Unidos
- El melanoma representa solo el 1% del cáncer de piel, pero es el que más muertes produce
- Para el 2025, se espera diagnosticar aproximadamente 104.960 casos nuevos de melanoma
- Se calcula que morirán 8.430 personas por melanoma

El estudio de imágenes dermatológicas mediante técnicas de inteligencia artificial representa un gran avance en el apoyo al diagnóstico temprano del cáncer de piel y otras lesiones cutáneas.




ALCANCES



01

Implementar y comparar modelos DNN y CNN para la clasificación de lesiones cutáneas, evaluando su precisión y capacidad de generalización.



02


Implementar autoencoders para la detección de lesiones malignas



03

Optimizar el preprocesamiento y entrenamiento mediante técnicas como Batch Normalization, Dropout para reducir el sobreajuste y mejorar la eficiencia computacional.

CONJUNTO DE DATOS



Variables principales:

- **image_id:** Identificador de la imagen
- **lesion_id:** Identificador de la lesión
- **dx:** Diagnóstico (clase de la lesión)
- **dx_type:** Tipo de diagnóstico (histo, follow_up, consensus, confocal)
- **age:** Edad del paciente
- **sex:** Sexo del paciente
- **localization:** Zona del cuerpo afectada

Clases de diagnóstico (dx):

- **akiec** – Queratosis actínica / carcinoma intraepitelial
- **bcc** – Carcinoma basocelular
- **bkl** – Lesión queratósica benigna
- **df** – Dermatofibroma
- **mel** – Melanoma
- **nv** – Nevo melanocítico (lunar)
- **vasc** – Lesión vascular

TIPOS DE LESIONES

“BKL” queratosis benigna (2)



“DF” dermatofibroma (3)



“Mel” melanoma (4)



“Vasc” Lesiones Vasculares (6)



TIPOS DE LESIONES

BCC carcinoma basocelular (1)




“NV” nevo melanocítico (5)



“Akiec” queratosis actínica (0)



DISTRIBUCIÓN DE CLASES



	Cantidad	Porcentaje (%)
diagnostico		
Nevo melanocítico	6705	66.95
Melanoma	1113	11.11
Queratosis benigna	1099	10.97
Carcinoma basocelular	514	5.13
Queratosis actínica	327	3.27
Lesiones vasculares	142	1.42
Dermatofibroma	115	1.15



ESTADO DEL ARTE



Inteligencia artificial para un diagnóstico accesible en la identificación del melanoma y otras lesiones

- **El estudio propone un sistema de diagnóstico accesible para detectar lesiones cutáneas mediante aprendizaje profundo. Usa la base de datos HAM10000, se usa data augmentation para balancear los datos y aplica redes neuronales convolucionales preentrenadas (VGG16, VGG19 y ResNet50)**

Clasificación eficaz del cáncer de piel mediante el modelo Inception-ResNet-V2 modificado y optimizado

- **ResNet50, EfficientNet B0, Inception-V3, and Inception-ResNet-V2, were studied, and the results revealed that they achieved accuracies of 93.90%, 94.37%, 94.87%, and 95.77%**



ESTADO DEL ARTE



ScNet: a lightweight CNN with depthwise and SE modules for skin lesion classification

- **Data augmentation**
- **The chosen models included ResNet50, InceptionV3, DenseNet121, MobileNetV3, and EfficientNet-B0**

ESTADO DEL ARTE





TABLA 1
MÉTRICAS DE LAS RNC OBTENIDAS CON LA METODOLOGÍA PROPUESTA


RNC	EXACTITUD	MACRO PROMEDIO			PROMEDIO PONDERADO		
		PRECISIÓN	SENSIBILIDAD	F1-SCORE	PRECISIÓN	SENSIBILIDAD	F1-SCORE
VGG16	0.95	0.95	0.95	0.95	0.95	0.95	0.95
VGG19	0.88	0.87	0.88	0.87	0.88	0.88	0.88
RESNET50	0.99	0.99	1.00	0.99	1.00	0.99	1.00

DIFICULTADES EN LA INVESTIGACIÓN




01

Desbalance de
clases pocas
muestras de algunas
lesiones.



02



Altos requerimientos
computacionales
para entrenar
modelos profundos.




PREPROCESAMIENTO



- Se combinan las dos partes del dataset
- Se redimensionaron a 128x128 con 3 canales
- Normalización
- Se codificaron las labels de texto a enteros
- Se usó codificación one hot para las CNN
- Dividir el dataset en 80% entrenamiento, 10% validación y 10% test con `train_test_split()`



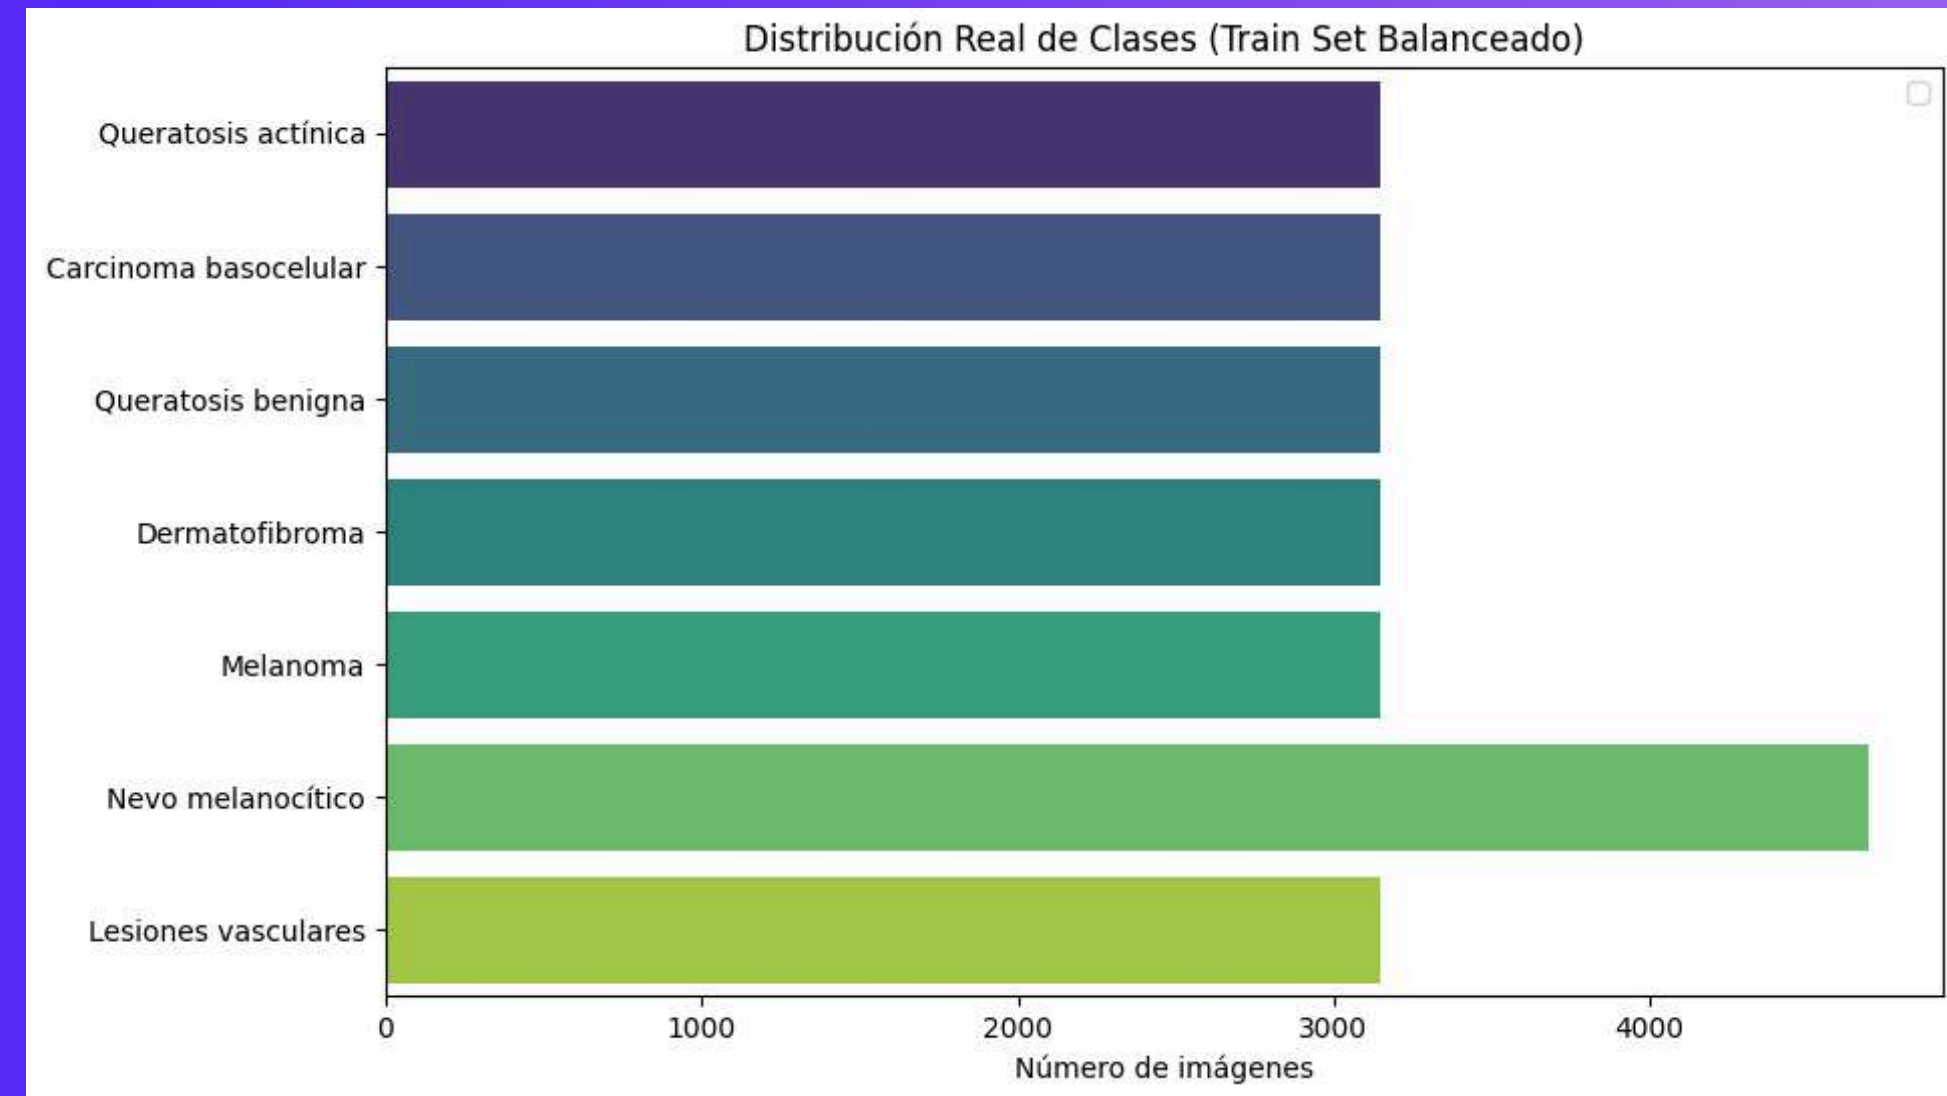


PREPROCESAMIENTO



- Se aplica data augmentation a las clases con menor cantidad de imagenes para que de este modo el modelo tengo una mayor precision a la hora de clasificar las lesiones

```
--- Distribución Post-Augmentation (Set de Entrenamiento) ---  
Clase 0 (Queratosis actínica): 3147 imágenes  
Clase 1 (Carcinoma basocelular): 3149 imágenes  
Clase 2 (Queratosis benigna): 3150 imágenes  
Clase 3 (Dermatofibroma): 3145 imágenes  
Clase 4 (Melanoma): 3150 imágenes  
Clase 5 (Nevo melanocítico): 4693 imágenes  
Clase 6 (Lesiones vasculares): 3145 imágenes
```



DNN

Arquitectura

- Flatten → Dense (1024,relu) → BatchNormalization() → Dropout(0,5)
- Dense(512, relu) → BatchNormalization() → Dropout(0.4)
- Dense(256, relu) → BatchNormalization() → Dropout(0.3)
- Dense(7, softmax)

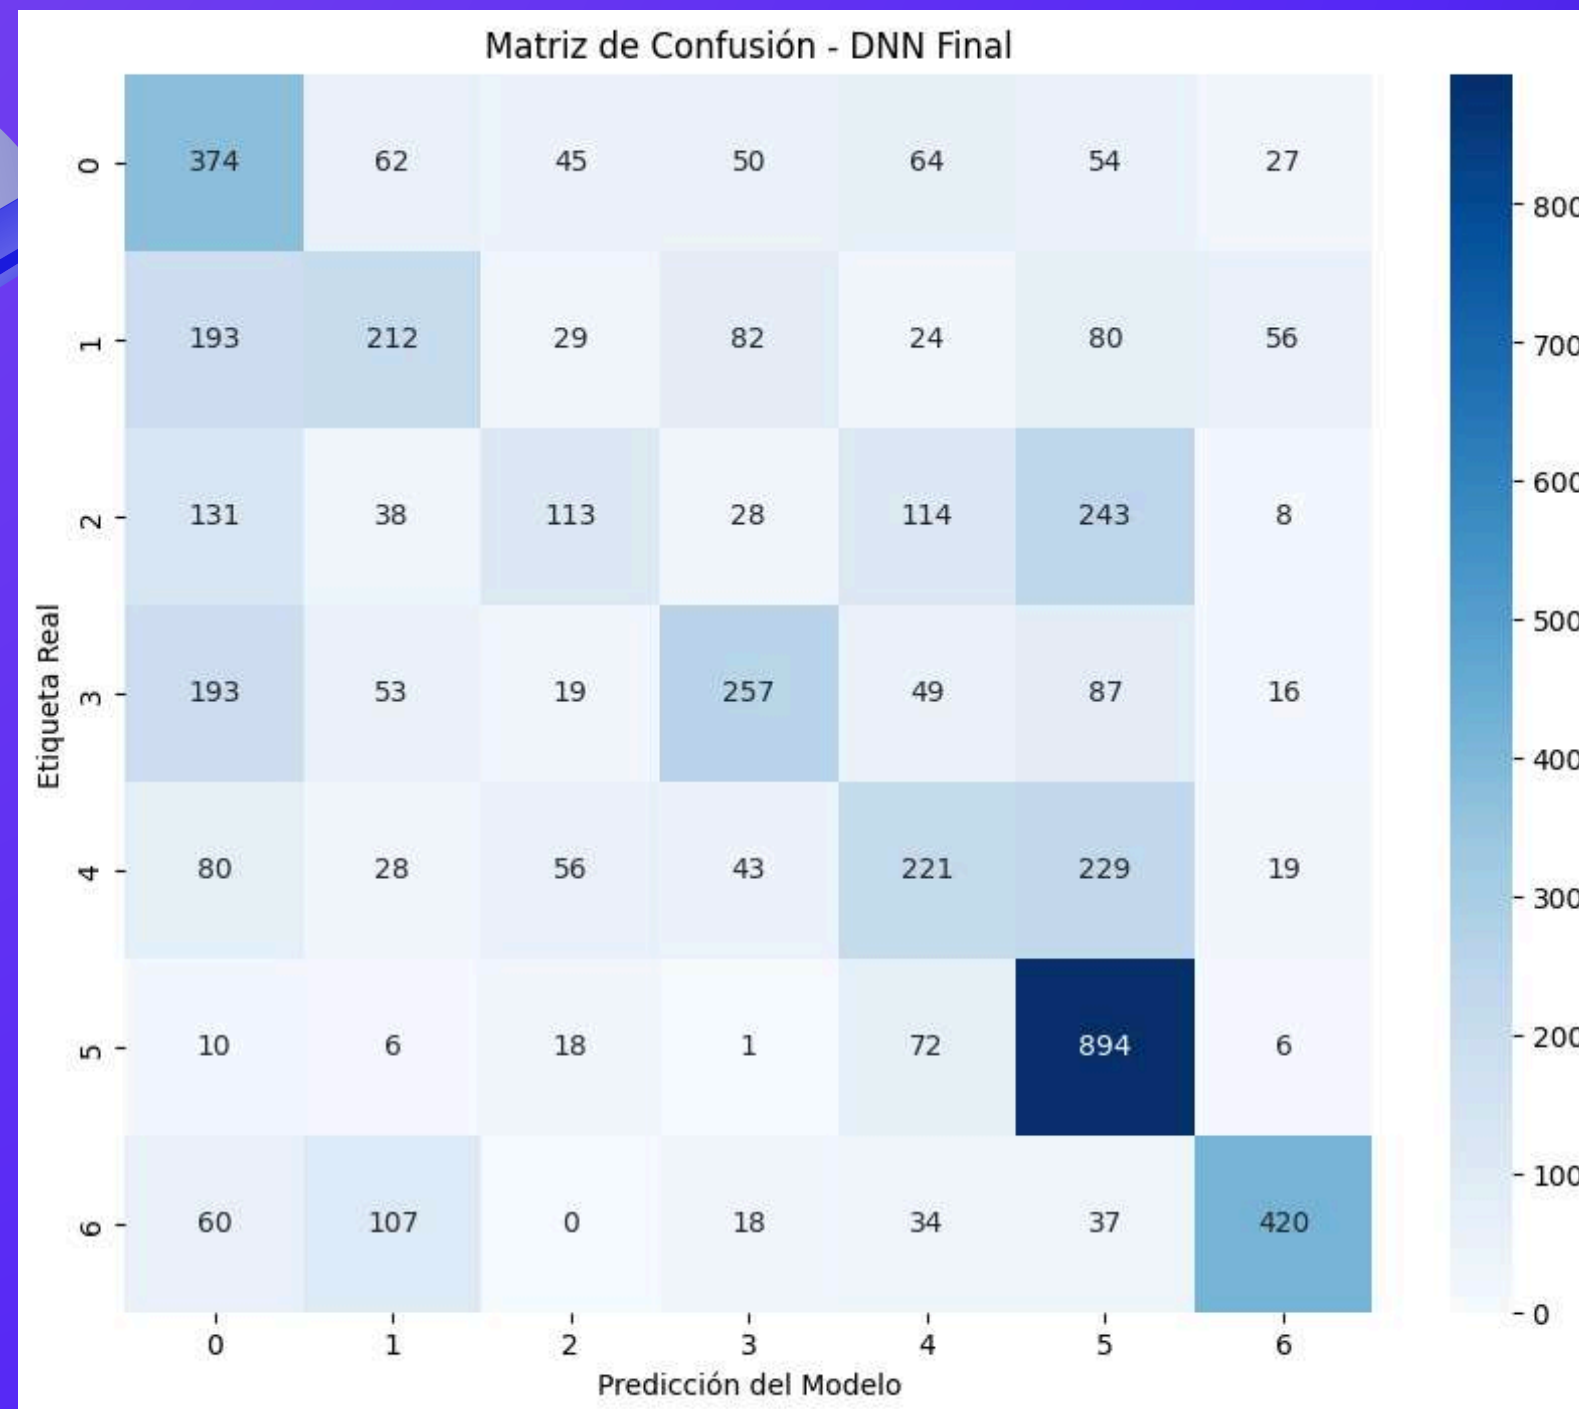
Entrenamiento

- Función de pérdida: Categorical Crossentropy
- Métricas: Accuracy
- 50 epochs
- Learning Rate = $1e-4$



RESULTADOS

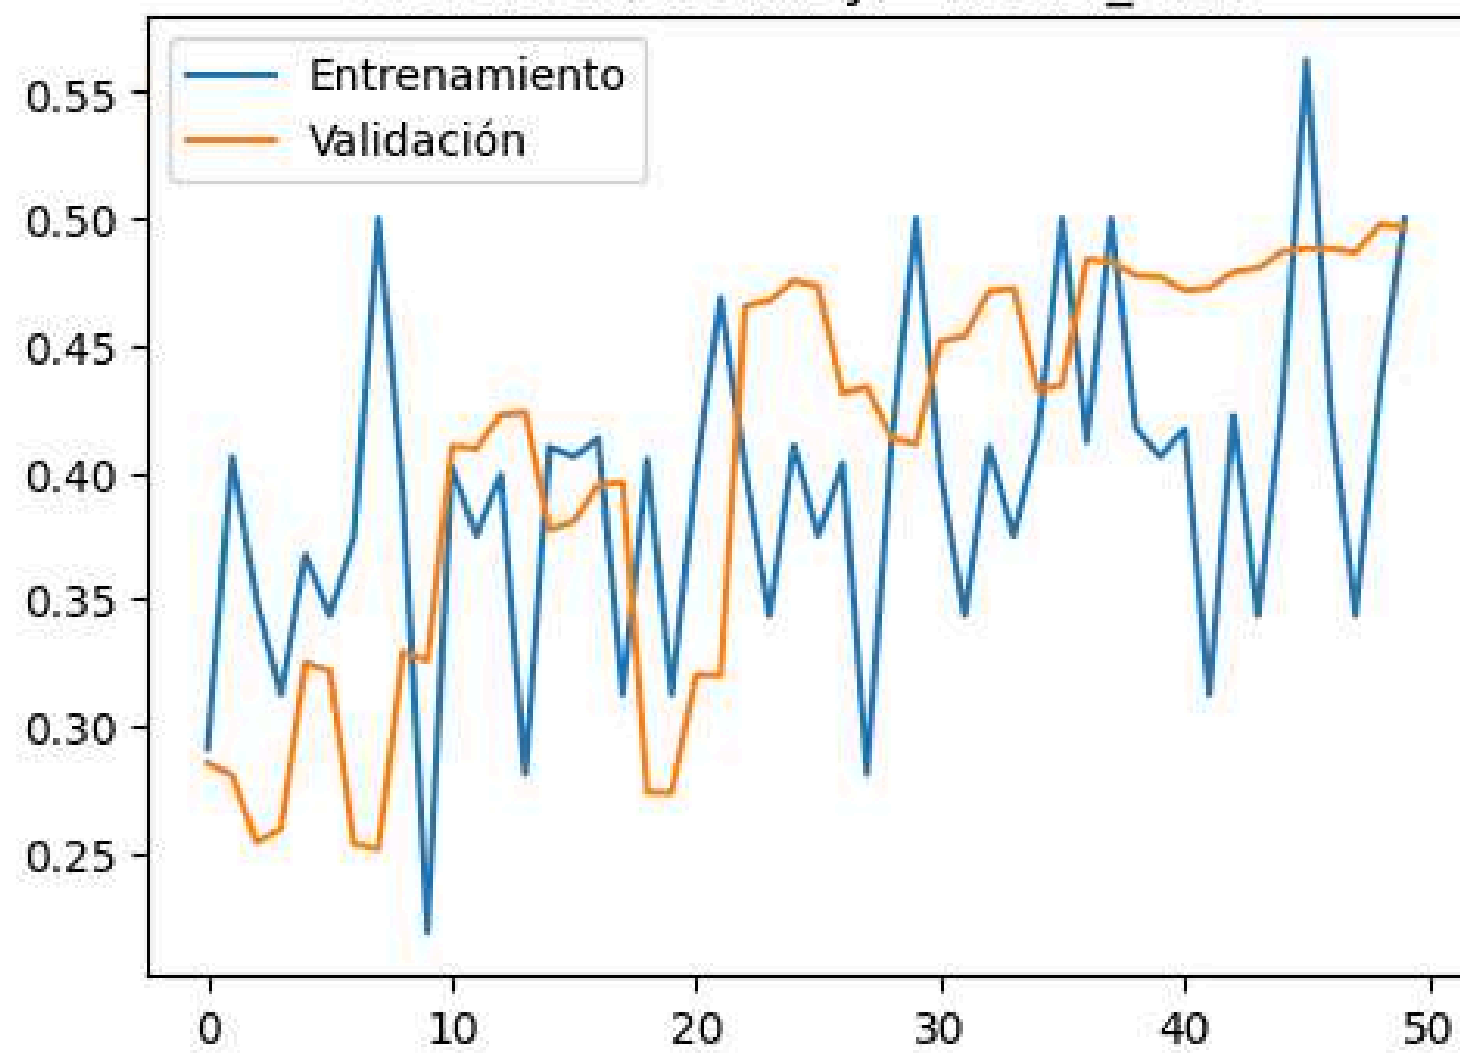
```
>>> AUC Promedio (Macro): 0.8557
>>> Accuracy Global: 0.4923
```



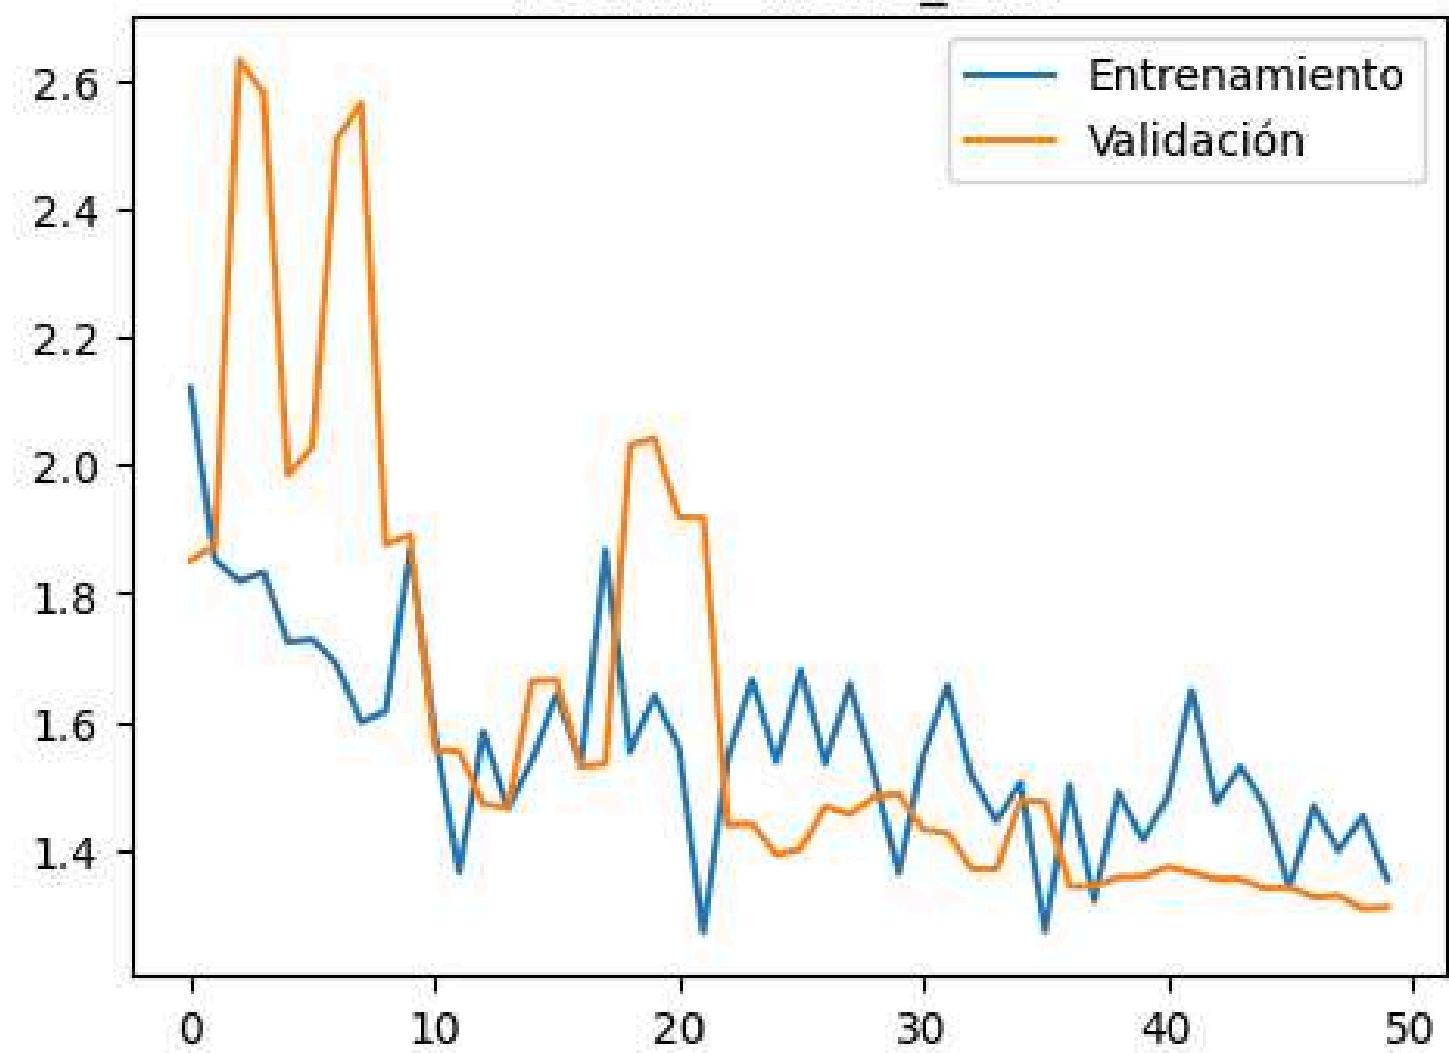
--- Desglose por Clase ---

	Precision	Recall	F1-Score
Clase			
0	0.3593	0.5533	0.4356
1	0.4190	0.3136	0.3587
2	0.4036	0.1674	0.2366
3	0.5365	0.3813	0.4458
4	0.3824	0.3269	0.3525
5	0.5505	0.8878	0.6796
6	0.7609	0.6213	0.6840

Exactitud (Accuracy) - model_DNN



Pérdida - model_DNN





CNN MANUAL



ARQUITECTURA

- 4 BLOQUES CONVOLUCIONALES: $32 \rightarrow 64 \rightarrow 128 \rightarrow 256$ FILTROS
- CADA BLOQUE: CONV2D(3X3) \rightarrow BATCHNORMALIZATION \rightarrow MAXPOOLING(2X2) \rightarrow DROPOUT
- CLASIFICADOR: GLOBALAVERAGEPOOLING \rightarrow DENSE(128) \rightarrow DROPOUT(0.5) \rightarrow SALIDA(7 CLASES)

CARACTERÍSTICAS PRINCIPALES

- INPUT: IMÁGENES $128 \times 128 \times 3$
- REGULARIZACIÓN PROGRESIVA: DROPOUT AUMENTA DE 0.2 A 0.5 EN CAPAS MÁS PROFUNDAS

ENTRENAMIENTO

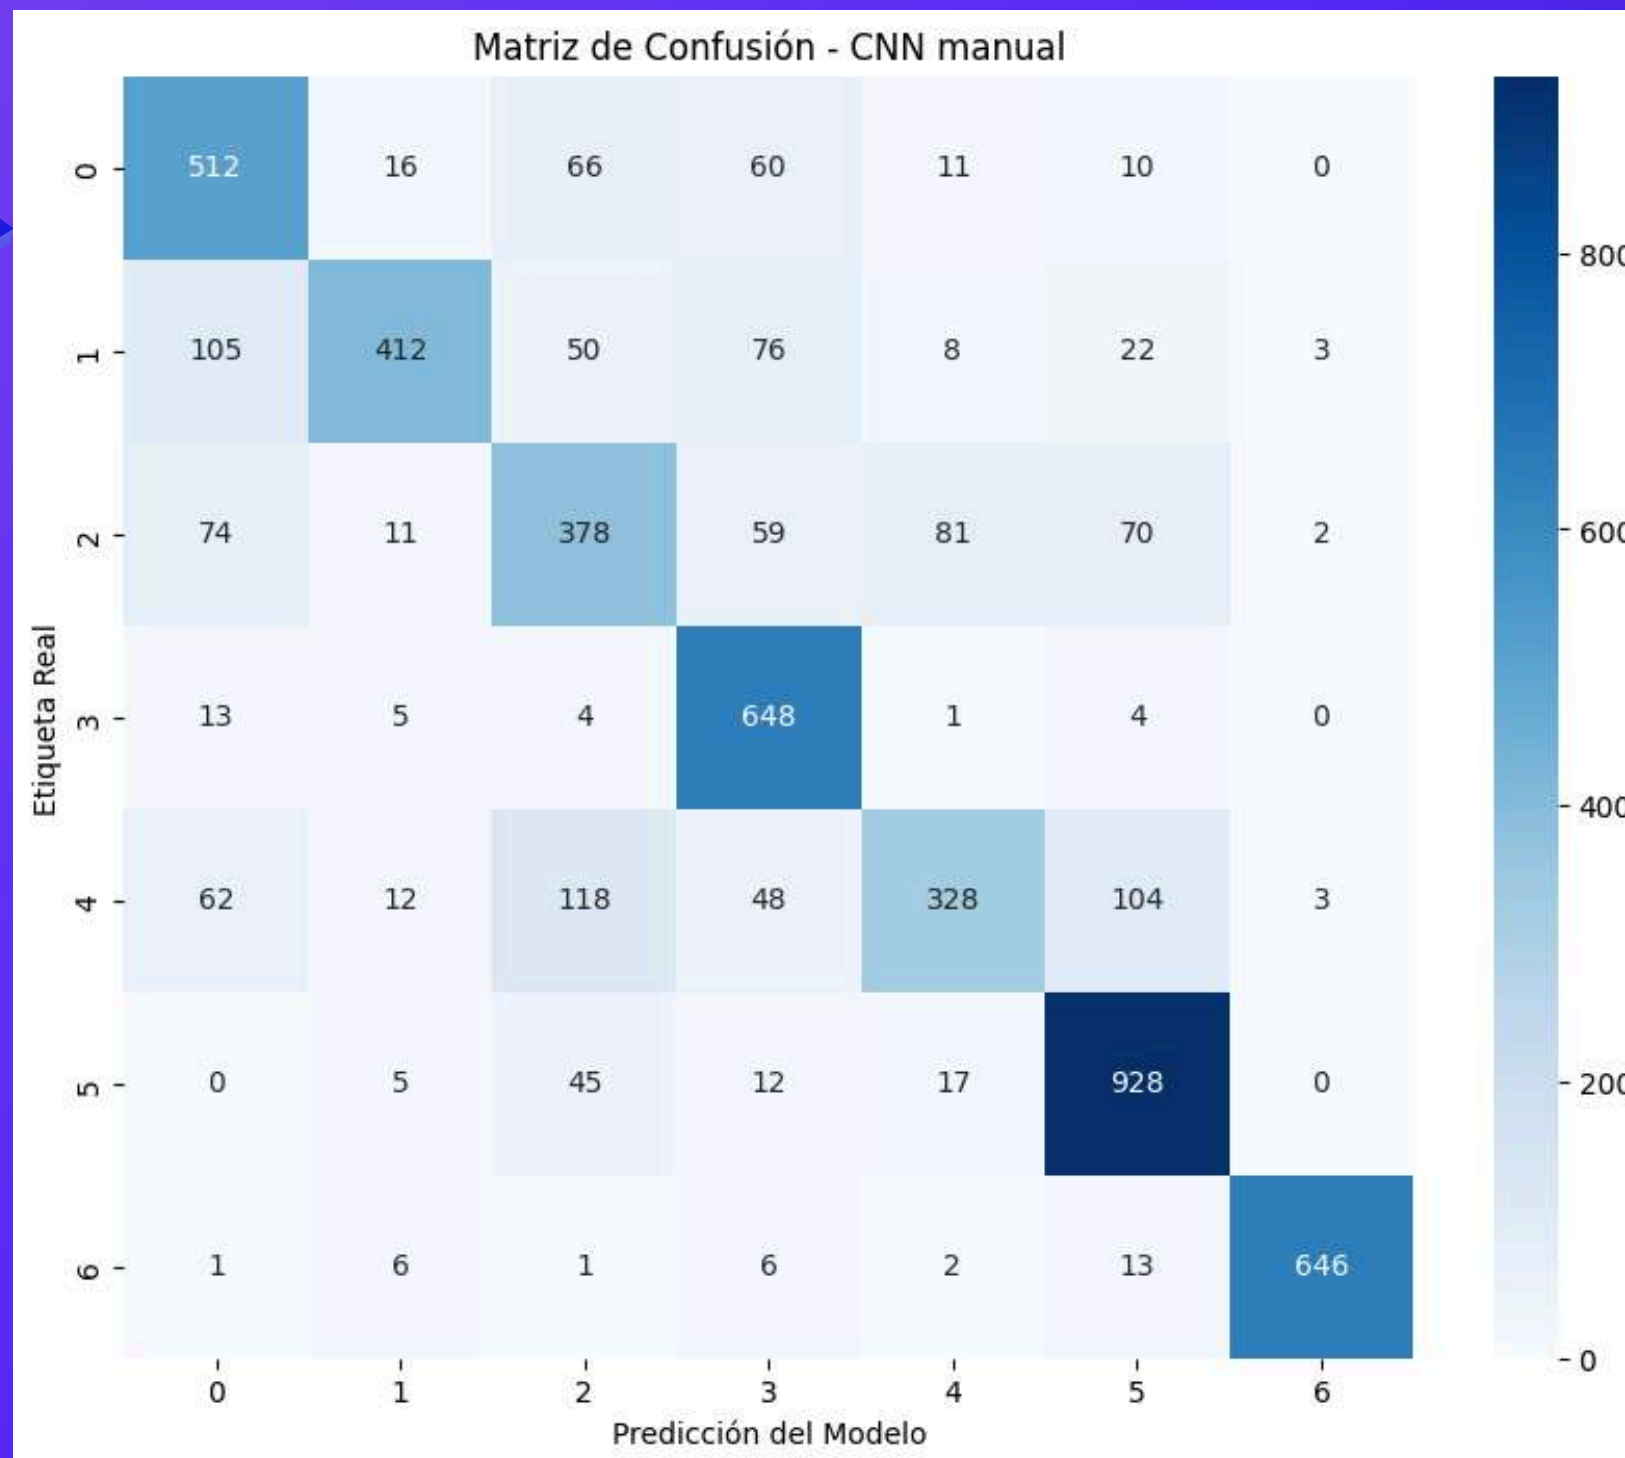
- OPTIMIZADOR: ADAM ($LR=1E-3$)
- FUNCIÓN DE PÉRDIDA: CATEGORICAL CROSSENTROPY
- MÉTRICAS: ACCURACY Y AUC

VENTAJAS DEL DISEÑO

- ARQUITECTURA PROFUNDA CAPTURA CARACTERÍSTICAS JERÁRQUICAS (BORDES \rightarrow TEXTURAS \rightarrow PATRONES COMPLEJOS)


RESULTADOS

```
>>> AUC Promedio (Macro): 0.9581
>>> Accuracy Global: 0.7616
```

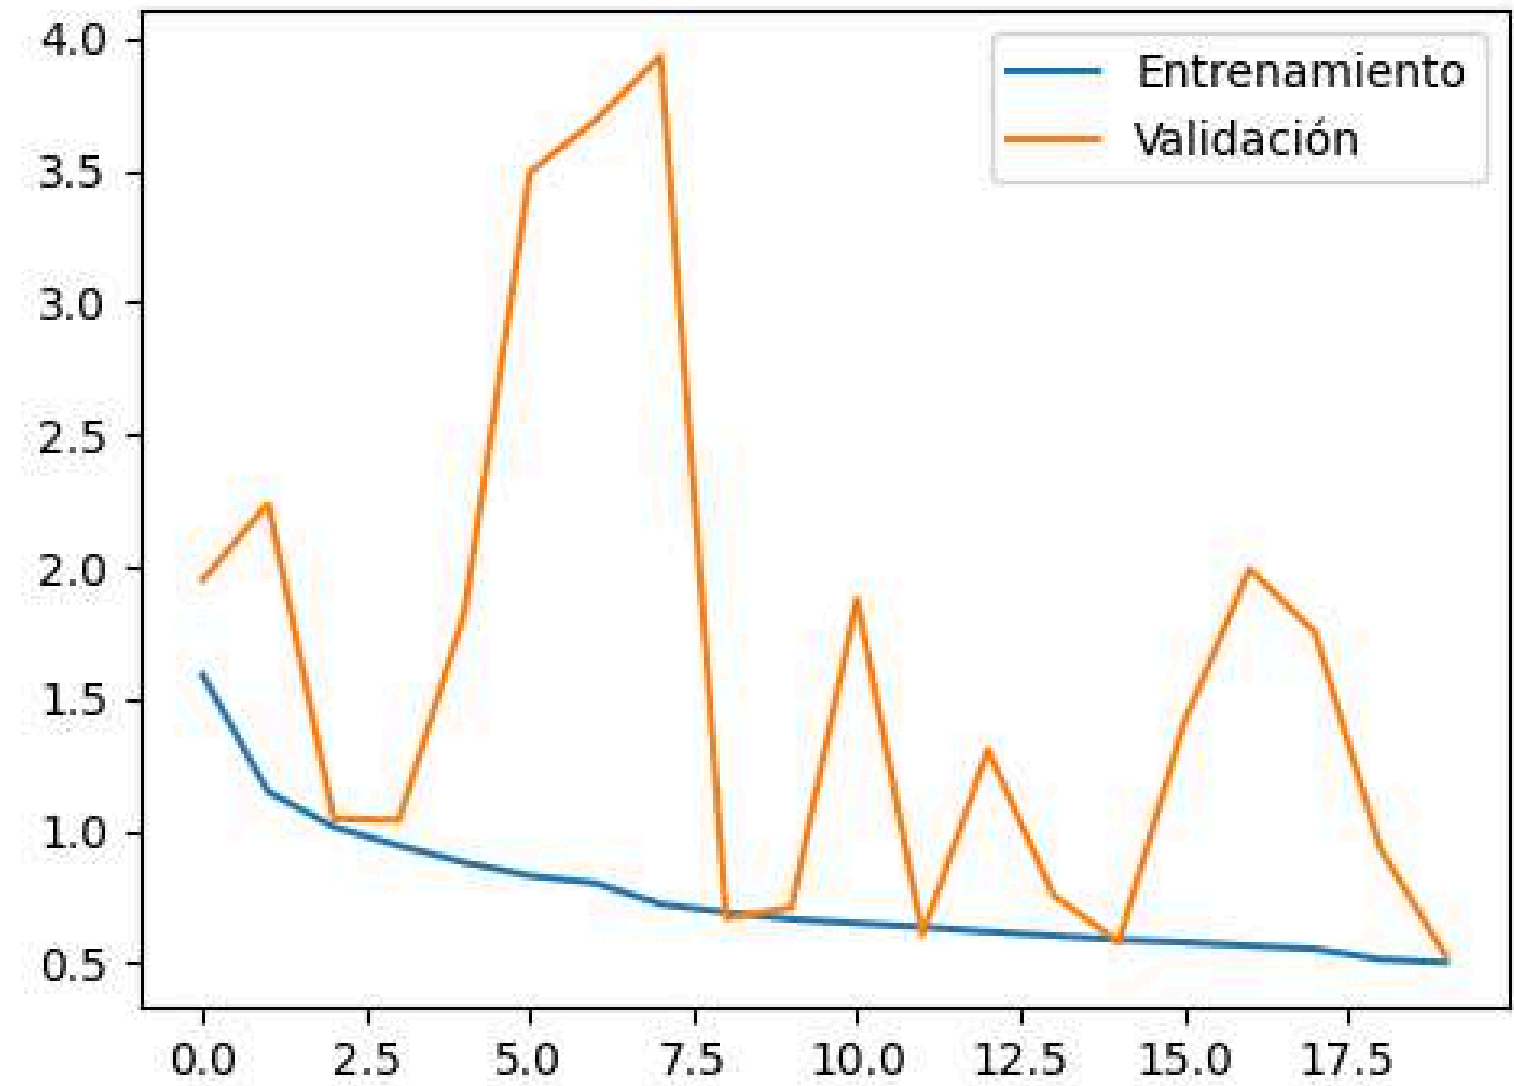


```
--- Desglose por Clase ---
      Precision  Recall  F1-Score
Clase
0      0.6675   0.7585   0.7101
1      0.8822   0.6095   0.7209
2      0.5710   0.5600   0.5654
3      0.7129   0.9600   0.8182
4      0.7321   0.4859   0.5841
5      0.8063   0.9215   0.8601
6      0.9878   0.9570   0.9722
```


Exactitud (Accuracy) - CNN manual



Pérdida - CNN manual



TRANSFER LEARNING

Arquitectura

- Base: **MobileNet** preentrenada en ImageNet (congelada inicialmente)
- Capas añadidas: GlobalAveragePooling → Dropout → Dense(256) → Salida(7 clases)

Entrenamiento en 2 Fases

Fase 1 – Transfer Learning (25 épocas)

- MobileNet congelada, solo se entrenan capas nuevas
- Learning rate: $1e-3$


Fase 2 – Fine-Tuning (30 épocas)

- Se descongelan últimas 20 capas de MobileNet
- Learning rate: $1e-5$




RESULTADOS

```
>>> AUC Promedio (Macro): 0.9769
>>> Accuracy Global: 0.8438
```

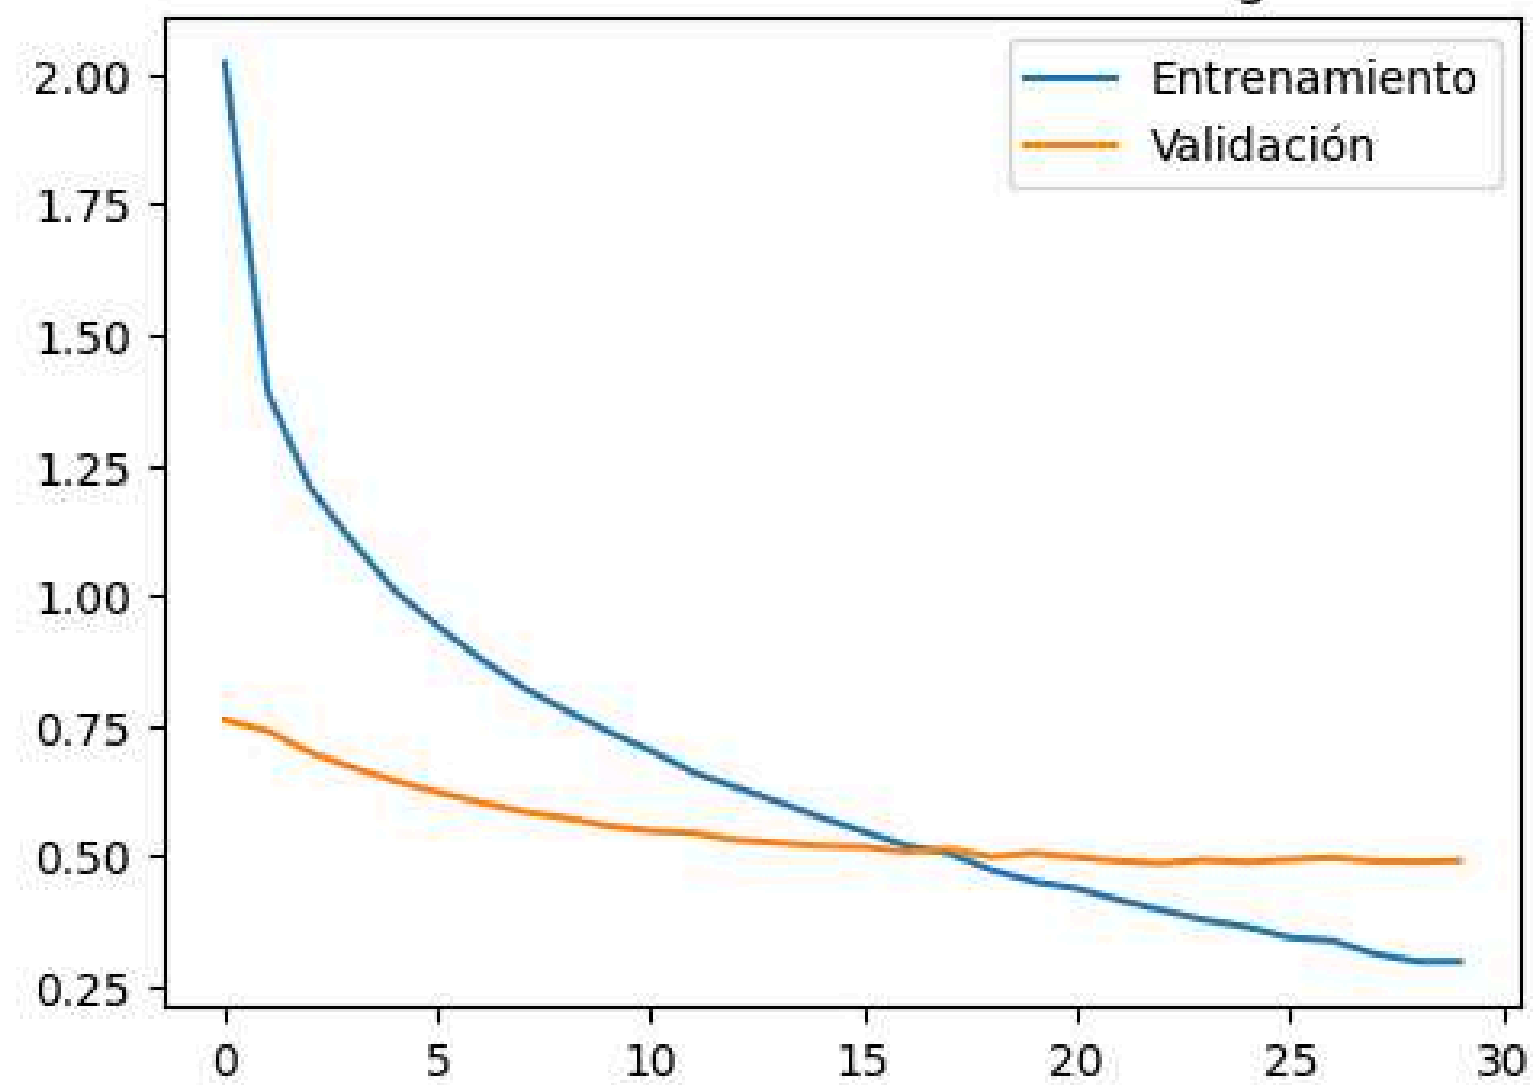


```
--- Desglose por Clase ---
      Precision  Recall  F1-Score
Clase
0      0.7912    0.8521    0.8205
1      0.8331    0.8578    0.8453
2      0.7091    0.6356    0.6703
3      0.9385    0.9719    0.9549
4      0.7423    0.6775    0.7084
5      0.8699    0.8967    0.8831
6      0.9867    0.9896    0.9882
```

Exactitud (Accuracy) - CNN Transfer Learning



Pérdida - CNN Transfer Learning



Modelo	Exactitud	Precisión macro	Recall macro	F1-score macro
DNN	0.4923	0.4874	0.4645	0.4561
CNN manual	0.7616	0.7657	0.7503	0.7473
CNN con transfer	0.8438	0.8387	0.8402	0.8316



AUTOENCODER PARA DETECCIÓN DE ANOMALIAS

Arquitectura:

- Input (128x128x3)
- **Encoder:**
 - 4 bloques Conv2D + BatchNorm + MaxPooling2D
 - Flatten + Dense: para compactar la información
- **Decoder:**
 - 4 bloques Conv2D + BatchNorm + UpSampling2D
 - Output: Conv2D(3, activación sigmoid) para regenerar la imagen

Entrenamiento

- Loss: Error cuadrático medio (MSE)
- Optimización: Adam, lr = $1e-4$

Se entrena solo con imágenes benignas

RESULTADOS

EVALUACIÓN EN TEST (MIXTO: BENIGNAS + MALIGNAS)

- CÁLCULO DEL ERROR DE RECONSTRUCCIÓN (MSE) PARA CADA IMAGEN.
- UMBRAL DE ANOMALÍA: PERCENTIL 95 DE LOS ERRORES BENIGNOS.
- CLASIFICACIÓN BINARIA:
 - $\text{ERROR} > \text{UMBRALE}$ → PREDICCIÓN: MALIGNA (ANOMALÍA)
 - $\text{ERROR} \leq \text{UMBRALE}$ → PREDICCIÓN: BENIGNA (NORMAL)

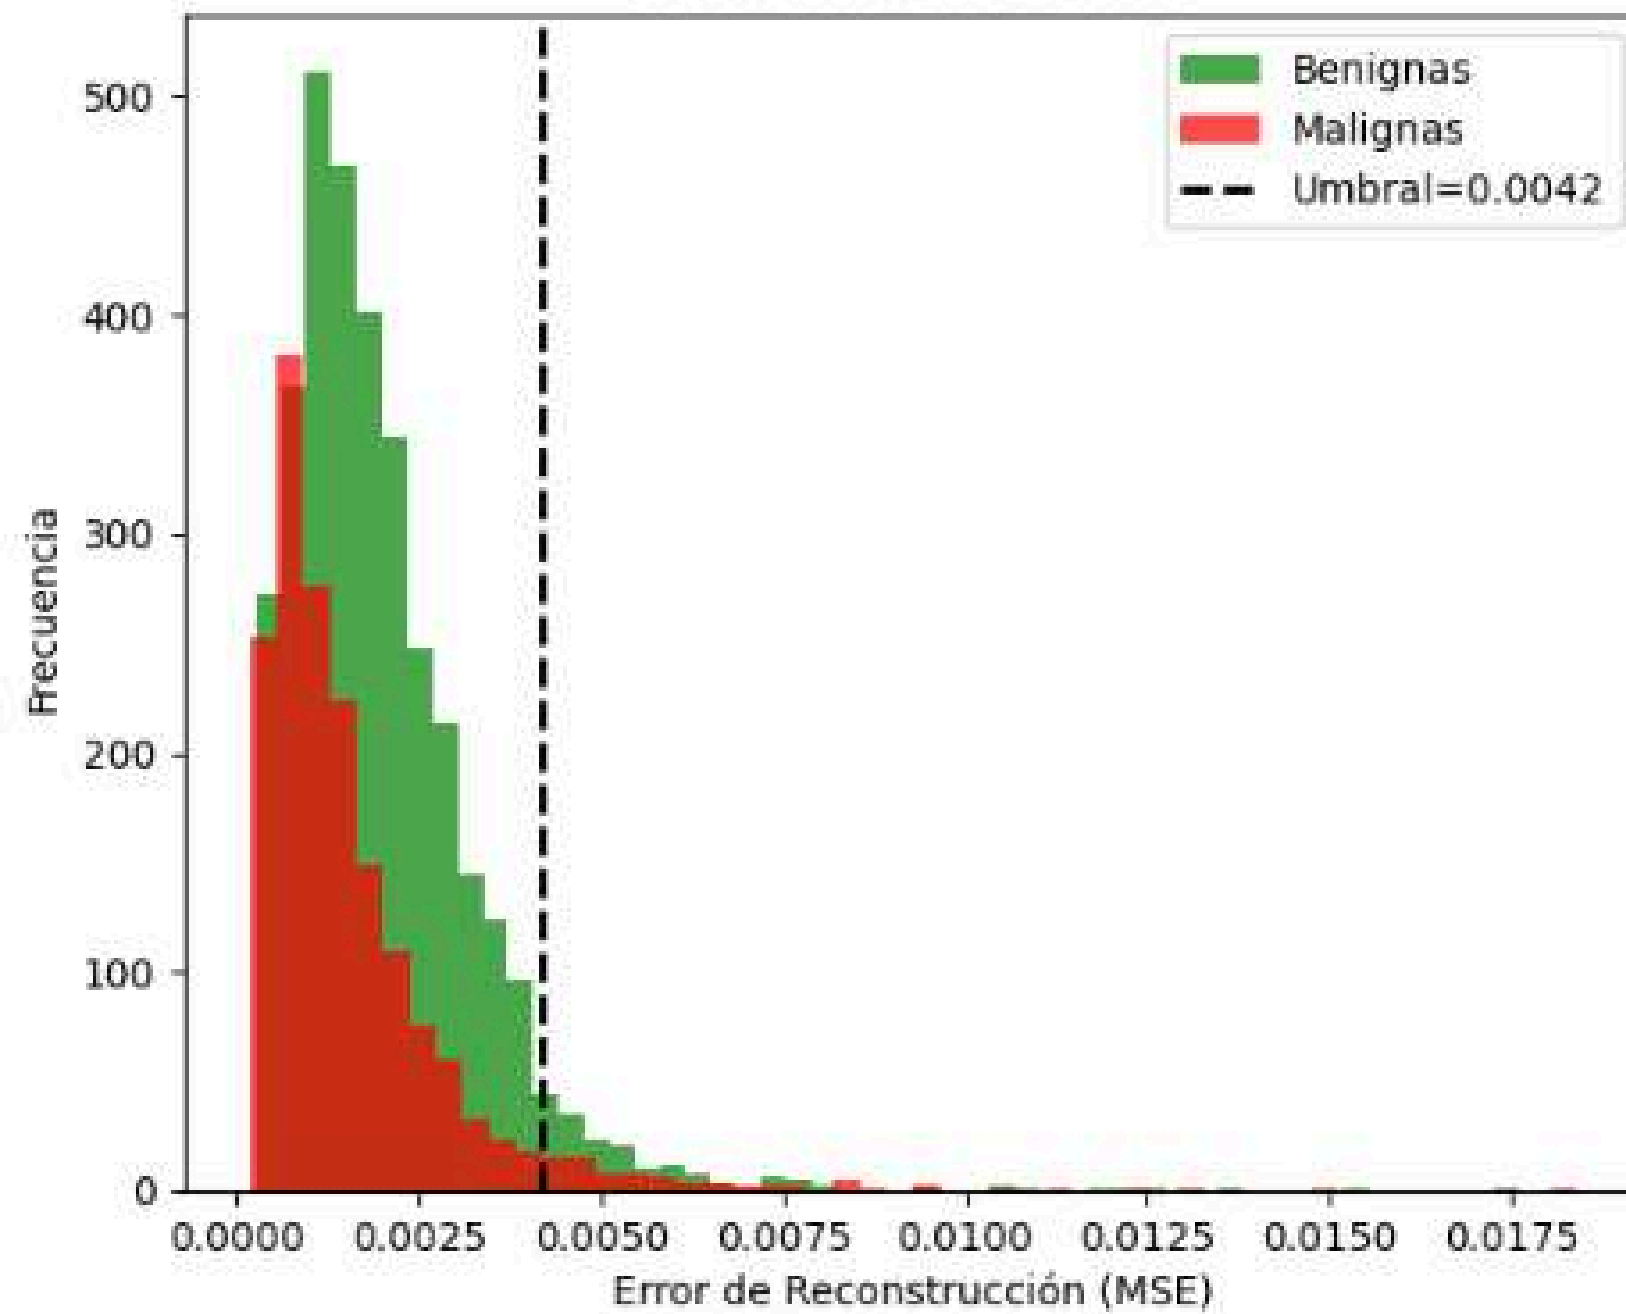
```
>>> Accuracy: 0.6501
>>> AUC-ROC: 0.3633

--- Classification Report ---
              precision    recall  f1-score   support

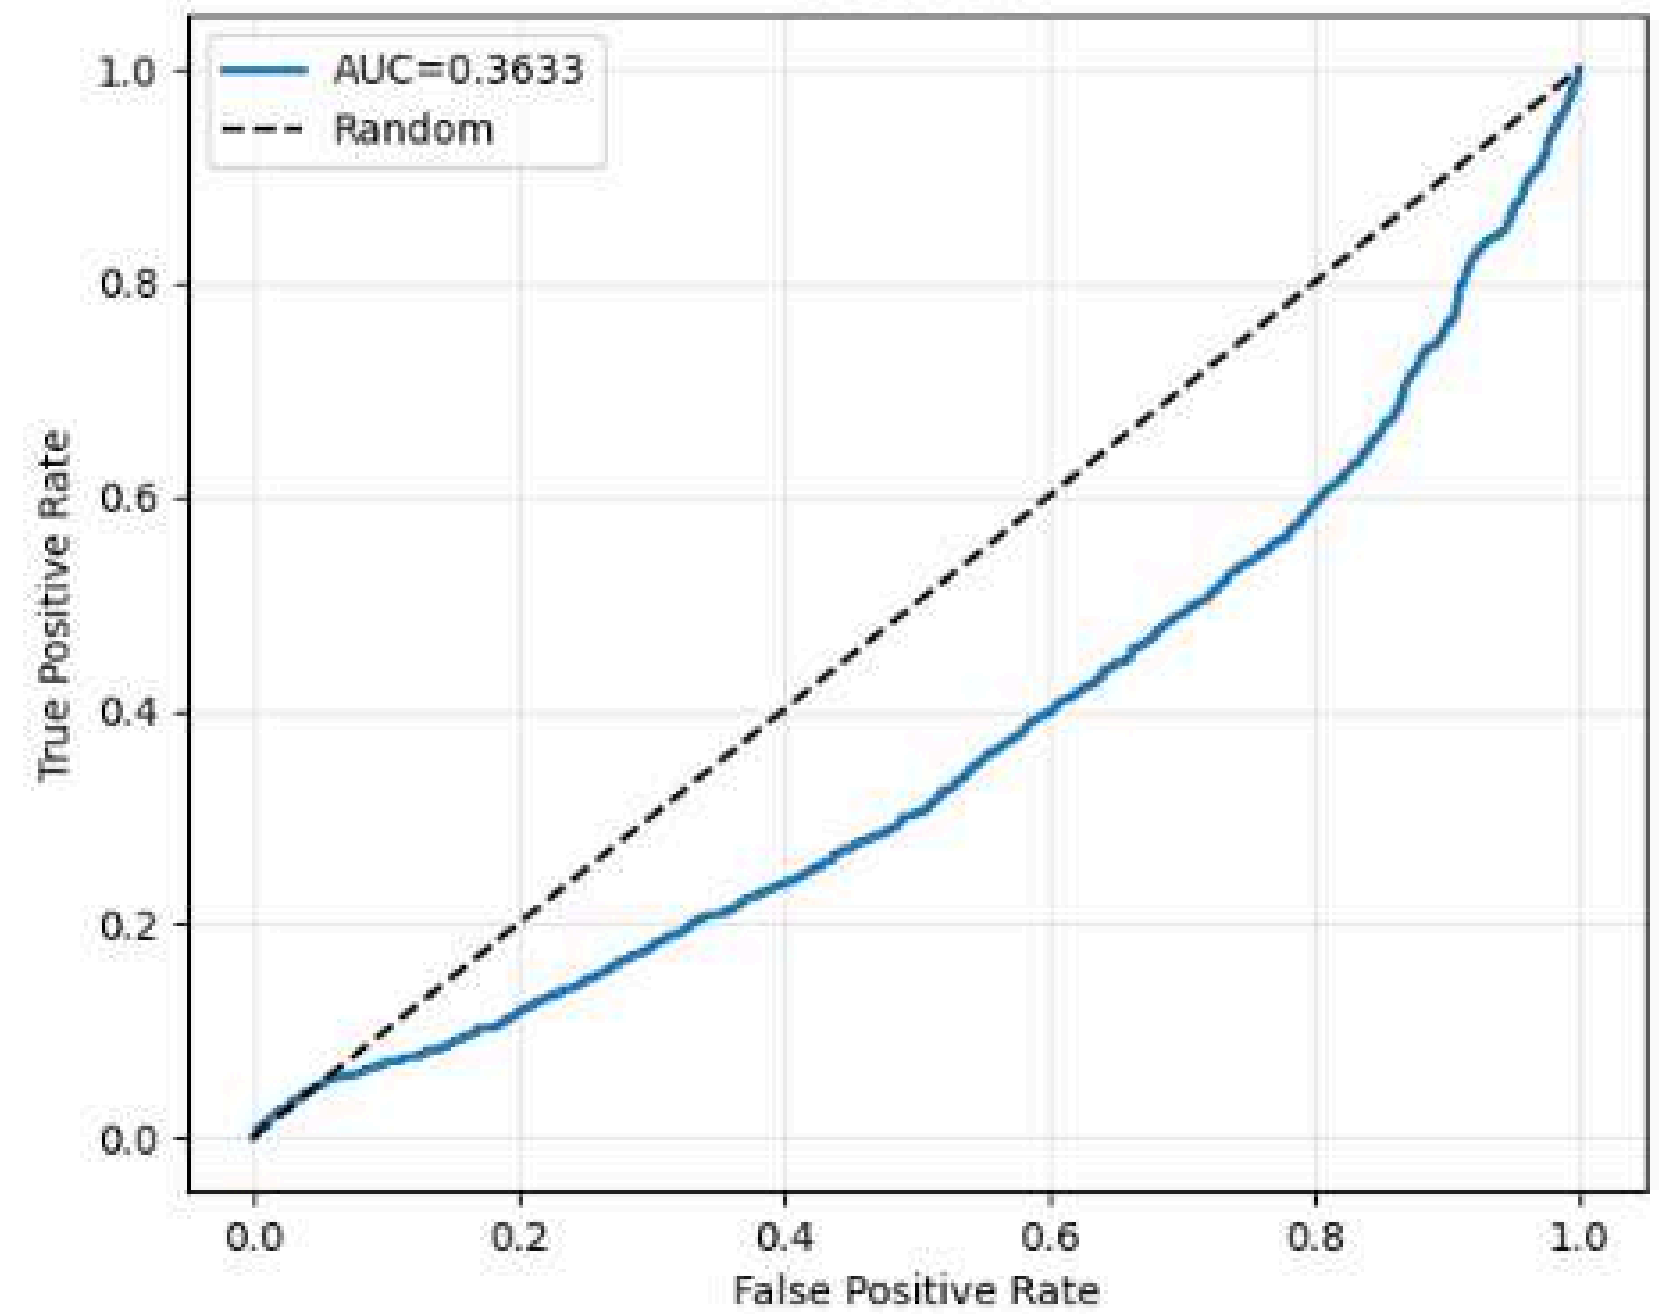
   Benigna      0.67      0.95      0.78      3375
   Maligna      0.33      0.05      0.08      1683

 accuracy              0.65      5058
 macro avg      0.50      0.50      0.43      5058
weighted avg      0.55      0.65      0.55      5058
```


Distribución de Errores




ROC Curve



Matriz de Confusión



Comparación de Errores



GRACIAS

